Badji Mokhtar University

Mini-projet sur le Supervised, Unsupervised and Deep Learning

Application aux Systèmes de Détection d'Intrusion (IDS)

Étudiants: Souilah Darine & Zehar Malek

Badji Mokhtar University — Computer Science Department

Date: 01/01/2026

PROF

Sommaire

1. **Introduction** 3
2. **Objectif du Projet** 4
3. **Datasets Utilisés** 5
4. **Prétraitement des Données** 6

- 4.1 UNSW-NB15 6
- 4.2 CICIDS2017 6
- 4.3 TonIoT 7

5. **Sélection des Caractéristiques** 8

- 5.1 Top 10 Caractéristiques par Dataset 8

6. **Méthodologie** 9

- 6.1 Apprentissage Supervisé (SL) 9
- 6.2 Apprentissage Non-Supervisé (USL) 10
- 6.3 Apprentissage Profond (DL) 11

7. **Résultats Expérimentaux** 12

- 7.1 Résultats sur UNSW-NB15 12
- 7.2 Résultats sur CICIDS2017 13
- 7.3 Résultats sur TonIoT 14
- 7.4 Comparaison Modèles Toutes Features vs Top 10 15

8. **Analyse des Résultats** 16

- 8.1 Sélection du Meilleur Modèle SL 16
- 8.2 Performance de l'Isolation Forest 16
- 8.3 Performance du LSTM 17

9. **Conclusion et Perspectives** 18
10. **Annexes** 19

- Annexe A: Pipeline LSTM Détaillé 19
- Annexe B: Isolation Forest - Détails des Seuils 20
- Annexe C: Références aux Scripts 21
- Annexe D: Exemples de Code Clés 22

\newpage

1. Introduction

Paragraphe 1 — La Détection d'Intrusion (IDS)
Les systèmes de détection d'intrusion (Intrusion Detection Systems - IDS) sont des composants essentiels de la sécurité réseau. Ils surveillent en permanence le trafic réseau et les activités système pour identifier les comportements suspects ou malveillants. Leur rôle principal est de détecter les attaques en temps réel et d'alerter les administrateurs pour une intervention rapide. Dans un contexte où les cybermenaces évoluent constamment, les approches traditionnelles basées sur des signatures deviennent insuffisantes, d'où l'intérêt croissant pour les méthodes basées sur l'apprentissage automatique.

Paragraphe 2 — Apprentissage Automatique et ses Parties (SL, USL)
L'apprentissage automatique (Machine Learning - ML) offre des solutions adaptatives pour la détection d'intrusion. L'apprentissage supervisé (Supervised Learning - SL) utilise des données étiquetées (normal/attaque) pour entraîner des modèles de classification. L'apprentissage non-supervisé (Unsupervised Learning - USL), quant à lui, détecte des anomalies sans nécessiter d'étiquettes préalables, en identifiant les déviations par rapport au comportement normal. Cette distinction est cruciale pour les IDS, où l'obtention d'étiquettes précises peut être coûteuse et difficile.

Paragraphe 3 — Apprentissage Profond (Deep Learning)
L'apprentissage profond (Deep Learning - DL) représente une avancée significative avec des architectures neuronales capables d'apprendre des représentations hiérarchiques complexes. Les réseaux LSTM (Long Short-Term Memory), en particulier, sont adaptés à la détection d'intrusion grâce à leur capacité à capturer des dépendances temporelles dans les flux réseau. Ils peuvent identifier des patterns d'attaque qui se déroulent sur plusieurs étapes temporelles, offrant ainsi une détection plus précise des attaques sophistiquées.

Paragraphe 4 — Objectif du Projet
Ce projet vise à comparer systématiquement les performances des approches SL, USL et DL sur trois datasets d'IDS représentatifs. L'objectif est double : premièrement, identifier le modèle le plus efficace pour chaque type d'apprentissage ; deuxièmement, évaluer l'impact de la sélection de caractéristiques (utilisation des 20 caractéristiques les plus importantes vs toutes les caractéristiques) sur les performances de détection. Cette étude fournira des recommandations pratiques pour le déploiement de systèmes IDS basés sur l'IA.

2. Objectif du Projet

Les objectifs spécifiques de ce projet sont :

PROF

1. **Tester et comparer** les algorithmes de ML (Random Forest, Decision Tree) pour l'apprentissage supervisé, l'Isolation Forest pour l'apprentissage non-supervisé, et le LSTM pour l'apprentissage profond.
2. **Évaluer** les performances sur trois datasets d'IDS différents (UNSW-NB15, CICIDS2017, TonIoT) pour assurer la robustesse des conclusions.
3. **Analyser** l'impact de la sélection des caractéristiques en comparant les résultats obtenus avec toutes les caractéristiques vs seulement les 20 plus importantes.
4. **Identifier** le meilleur modèle d'apprentissage supervisé pour la détection d'intrusion en fonction des métriques critiques (recall, AUC).
5. **Fournir** des recommandations pratiques pour le choix des modèles et des paramètres dans des scénarios réels de déploiement.

3. Datasets Utilisés

Dataset	Fichiers Utilisés	Taille Initiale	Caractéristiques Initiales	Types d'Attaques	Taille Après Prétraitement
UNSW-NB15	UNSW_NB15_training-set.csv UNSW_NB15_testing-set.csv	2,540,044 enregistrements	49 caractéristiques	9 types (Fuzzers, Analysis, Backdoors, DoS, Exploits, Generic, Reconnaissance, Shellcode, Worms)	2,218,761 enregistrements
CICIDS2017	Monday-WorkingHours.pcap_ISCX.csv Tuesday-WorkingHours.pcap_ISCX.csv Wednesday-WorkingHours.pcap_ISCX.csv Thursday-WorkingHours.pcap_ISCX.csv Friday-WorkingHours.pcap_ISCX.csv	2,830,743 enregistrements	84 caractéristiques	15 types (Brute Force, Heartbleed, Botnet, DDoS, DoS, Web Attacks, Infiltration)	2,678,342 enregistrements
TonIoT	ton_iot_final.csv	~650,000 enregistrements	45 caractéristiques	7 types (DDoS, DoS, Injection, MITM, Password, Ransomware, Scanning)	621,450 enregistrements

Note : Les tailles après prétraitement dépendent des opérations de nettoyage appliquées.

---

4. Prétraitement des Données

4.1 UNSW-NB15

PROF

- **Fichiers utilisés** : UNSW_NB15_training-set.csv, UNSW_NB15_testing-set.csv
- **Caractéristiques supprimées** :
  - id : Identifiant unique
  - srcip, dstip : Adresses IP (non pertinentes pour la modélisation)
  - sport, dsport : Ports source et destination
  - stime, ltime : Timestamps
- **Opérations appliquées** :
  1. Suppression des colonnes non informatives
  2. Traitement des valeurs manquantes (médiane pour les numériques, mode pour les catégorielles)
  3. Encodage des variables catégorielles (proto, service, state) avec LabelEncoder
  4. Normalisation avec StandardScaler
  5. Équilibrage des classes avec SMOTE (optionnel)

Code 6 — Pipeline de prétraitement pour UNSW-NB15

```
# Pipeline de prétraitement pour UNSW-NB15
from sklearn.preprocessing import LabelEncoder, StandardScaler

def preprocess_unsw(data):
    # 1. Suppression colonnes non pertinentes
    data = data.drop(columns=['id', 'srcip', 'dstip', 'sport', 'dsport'])

    # 2. Encodage variables catégorielles
    for col in ['proto', 'service', 'state']:
        data[col] = LabelEncoder().fit_transform(data[col])

    # 3. Normalisation
    scaler = StandardScaler()
    return scaler.fit_transform(data)
```

- **Caractéristiques finales** : 40 caractéristiques (après prétraitement initial)

4.2 CICIDS2017

- **Fichiers utilisés** : Fichiers CSV journaliers de Monday à Friday
- **Caractéristiques supprimées** :
  - Flow ID, Src IP, Dst IP : Identifiants et adresses
  - Timestamp : Information temporelle
  - Fwd Header Length, Bwd Header Length : Redondantes
- **Opérations appliquées** :
  1. Fusion des fichiers journaliers
  2. Suppression des features avec variance nulle
  3. Traitement des valeurs infinies et NaN
  4. Encodage one-hot pour les protocoles
  5. Standardisation MinMaxScaler
- **Caractéristiques finales** : 78 caractéristiques (après prétraitement initial)

4.3 TonIoT

- **Fichiers utilisés** : ton_iot_final.csv
- **Caractéristiques supprimées** :
  - ts : Timestamp
  - src_ip, dst_ip : Adresses IoT
  - src_port, dst_port : Ports
- **Opérations appliquées** :
  1. Filtrage des valeurs aberrantes (IQR method)
  2. Encodage des types de dispositifs IoT
  3. Normalisation RobustScaler (résistant aux outliers)
  4. Réduction de dimension avec PCA (optionnel)
- **Caractéristiques finales** : 38 caractéristiques (après prétraitement initial)

PROF

---

5. Sélection des Caractéristiques

5.1 Top 20 Caractéristiques par Dataset

UNSW-NB15 — Top 20 Features

1. dur - Durée de la connexion

2. sbytes - Bytes source
3. dbytes - Bytes destination
4. sttl - TTL source
5. dttl - TTL destination
6. sloss - Paquets perdus source
7. dloss - Paquets perdus destination
8. sload - Load source
9. dload - Load destination
10. spkts - Paquets source
11. dpkts - Paquets destination
12. swin - Window size source
13. dwin - Window size destination
14. stcpb - TCP base sequence number source
15. dtcpb - TCP base sequence number destination
16. smeansz - Mean flow packet size source
17. dmeansz - Mean flow packet size destination
18. trans_depth - Transaction depth
19. res_bdy_len - Response body length
20. sjit - Jitter source

CICIDS2017 — Top 20 Features

1. Flow Duration
2. Total Fwd Packets
3. Total Backward Packets
4. Fwd Packet Length Max
5. Fwd Packet Length Min
6. Fwd Packet Length Mean
7. Bwd Packet Length Max
8. Bwd Packet Length Mean
9. Flow Bytes/s
10. Flow Packets/s
11. Flow IAT Mean
12. Flow IAT Std
13. Flow IAT Max
14. Fwd IAT Total
15. Fwd IAT Mean
16. Bwd IAT Total
17. Bwd IAT Mean
18. Fwd PSH Flags
19. Bwd PSH Flags
20. Fwd Header Length

TonIoT — Top 20 Features

1. pktcount - Nombre de paquets
2. bytecount - Nombre d'octets
3. dur - Durée du flux
4. rate - Taux de transmission
5. tcp_retransmit - Retransmissions TCP
6. tcp_ack - ACK TCP
7. tcp_win - Window TCP
8. tcp_rtt - RTT TCP
9. http_method - Méthode HTTP
10. http_ret - Code retour HTTP

PROF

11. dns_query - Requêtes DNS
12. dns_qtype - Type de requête DNS
13. src_bytes - Bytes source
14. dst_bytes - Bytes destination
15. src_pkts - Paquets source
16. dst_pkts - Paquets destination
17. src_ip_bytes - IP bytes source
18. dst_ip_bytes - IP bytes destination
19. proto - Protocole
20. conn_state - État de connexion

Code 1 — Sélection des Top 20 caractéristiques (Random Forest)

```
# Sélection des Top 20 caractéristiques avec Random Forest
import numpy as np
from sklearn.ensemble import RandomForestClassifier

def get_top_features(X, y, n_features=20):
    rf = RandomForestClassifier(n_estimators=100, random_state=42)
    rf.fit(X, y)
    importances = rf.feature_importances_
    indices = np.argsort(importances)[::-1]  # Tri décroissant
    return X.columns[indices[:n_features]]
```

Note : Ces listes sont basées sur l'importance des caractéristiques calculée par Random Forest.

Figure — Top 20 Feature Importance Bar Chart

Top 20 Features Bar Chart

---

6. Méthodologie

6.1 Apprentissage Supervisé (SL)

Split des Données

- **Ratio** : 70% entraînement, 15% validation, 15% test
- **Méthode** : Split stratifié pour préserver la distribution des classes
- **Validation croisée** : 5-fold cross-validation pour l'optimisation des hyperparamètres

PROF

Paramètres des Modèles

Random Forest (RF) :

- n_estimators : 100, 200, 300 (testés)
- max_depth : 10, 15, 20, None
- min_samples_split : 2, 5, 10
- min_samples_leaf : 1, 2, 4
- max_features : 'sqrt', 'log2'
- random_state : 42 pour la reproductibilité

Decision Tree (DT) :

- criterion : 'gini', 'entropy'
- max_depth : 5, 10, 15, 20, None
- min_samples_split : 2, 5, 10

- min_samples_leaf : 1, 2, 4
- random_state : 42

Code 2 — Optimisation hyperparamètres (Random Forest)

```
# Optimisation hyperparamètres Random Forest
from sklearn.model_selection import GridSearchCV
from sklearn.ensemble import RandomForestClassifier

param_grid = {
    'n_estimators': [100, 200, 300],
    'max_depth': [10, 15, 20, None],
    'min_samples_split': [2, 5, 10]
}

grid_search = GridSearchCV(
    RandomForestClassifier(random_state=42),
    param_grid,
    cv=5,
    scoring='recall',  # Priorité pour IDS
    n_jobs=-1
)
```

Métriques d'Évaluation

- **Accuracy** : (TP + TN) / Total
- **Recall (Sensibilité)** : TP / (TP + FN) - *métrique principale pour les IDS*
- **Precision** : TP / (TP + FP)
- **F1-Score** : 2 × (Precision × Recall) / (Precision + Recall)
- **AUC-ROC** : Area Under the ROC Curve
- **Matrice de Confusion** : Visualisation des vrais/faux positifs/négatifs

6.2 Apprentissage Non-Supervisé (Isolation Forest)

Préparation des Données

- **Données normales** : Sous-ensemble d'entraînement contenant seulement les échantillons normaux (label=0)
- **Données de test** : Mélange normal/attaque pour évaluation

PROF

Paramètres

- n_estimators : 100, 200
- max_samples : 'auto', 256, 512
- contamination : 0.05, 0.1, 0.15 (testés)
- random_state : 42

Threshold Calculation Method: Youden's J Index

Méthode utilisée : Maximisation du score Youden's J

L'Isolation Forest génère des scores d'anomalie pour chaque observation. Pour convertir ces scores en prédictions binaires (normal/attaque), nous devons déterminer un seuil optimal. La méthode de l'indice de Youden offre un équilibre optimal entre la sensibilité (taux de vrais positifs) et la spécificité (taux de vrais négatifs).

Method used: Maximization of Youden's J = Sensitivity + Specificity - 1

L'indice de Youden (J) est calculé comme suit :

- **J = Sensitivity + Specificity - 1**
- Équivalent à : **J = TPR - FPR** (True Positive Rate - False Positive Rate)
- Le seuil optimal est celui qui maximise cette valeur

Process :

1. Calcul des scores d'anomalie pour l'ensemble de validation
2. Génération de la courbe ROC
3. Calcul de J pour chaque seuil possible
4. Sélection du seuil maximisant J

Code 4 — Sélection du seuil optimal avec Youden's J (Isolation Forest)

```
# Sélection du seuil optimal avec Youden's J
from sklearn.metrics import roc_curve
import numpy as np

def find_optimal_threshold(y_true, anomaly_scores):
    fpr, tpr, thresholds = roc_curve(y_true, -anomaly_scores)
    youden_j = tpr - fpr  # Youden's J = TPR - FPR
    optimal_idx = np.argmax(youden_j)
    return thresholds[optimal_idx]
```

6.3 Apprentissage Profond (LSTM)

Pipeline LSTM

Le réseau LSTM (Long Short-Term Memory) est une architecture de deep learning particulièrement adaptée à la détection d'intrusion grâce à sa capacité à capturer les dépendances temporelles dans les séquences de trafic réseau. Le pipeline LSTM transforme les données tabulaires en séquences temporelles, permettant au modèle d'apprendre des patterns d'attaque qui se déploient sur plusieurs étapes temporelles consécutives.

Description du Pipeline :

Le pipeline LSTM suit une approche structurée en plusieurs étapes :

1. **Séquençage des données** : Les observations individuelles sont regroupées en séquences de longueur fixe (timesteps). Par exemple, avec timesteps=10, chaque échantillon d'entraînement contient 10 observations consécutives du trafic réseau, permettant au modèle de détecter des patterns temporels comme les phases d'une attaque DDoS.

2. **Normalisation adaptée** : Application d'un StandardScaler sur les données séquentielles pour garantir que toutes les caractéristiques sont à la même échelle, ce qui améliore la convergence du réseau neuronal.

3. **Architecture neuronale profonde** : Construction d'un réseau à plusieurs couches LSTM empilées avec des mécanismes de régularisation (Dropout) pour prévenir le surapprentissage. La première couche LSTM capture les patterns de bas niveau tandis que la seconde couche extrait des représentations de plus haut niveau.

4. **Compilation et optimisation** : Configuration de la fonction de perte (binary_crossentropy pour la classification binaire) et de l'optimiseur Adam avec un taux d'apprentissage adaptatif pour une convergence efficace.

5. **Entraînement avec Early Stopping** : Entraînement du modèle avec surveillance de la performance sur un ensemble de validation, en arrêtant automatiquement l'entraînement si aucune amélioration n'est observée pendant plusieurs epochs (patience=5), évitant ainsi le surapprentissage.

Architecture Détaillée :

1. **Séquençage** : Transformation en séquences de longueur fixe (timesteps=10)
2. **Normalisation** : StandardScaler adapté aux données séquentielles

PROF

3. **Architecture** :
    - Couche LSTM(64) avec return_sequences=True
    - Dropout(0.2)
    - Couche LSTM(32)
    - Dropout(0.2)
    - Dense(16, activation='relu')
    - Dense(1, activation='sigmoid')
4. **Compilation** :
    - Optimizer : Adam(learning_rate=0.001)
    - Loss : binary_crossentropy
    - Metrics : ['accuracy', 'recall']
5. **Entraînement** :
    - Batch size : 32
    - Epochs : 50
    - Validation split : 0.2
    - Early stopping : Patience=5

Code 3 — Architecture LSTM (TensorFlow/Keras)

```
# Architecture LSTM avec TensorFlow/Keras
from tensorflow.keras import Sequential
from tensorflow.keras.layers import LSTM, Dense, Dropout

def build_lstm_model(timesteps, n_features):
    model = Sequential([
        LSTM(64, return_sequences=True, input_shape=(timesteps, n_features)),
        Dropout(0.2),
        LSTM(32),
        Dropout(0.2),
        Dense(16, activation='relu'),
        Dense(1, activation='sigmoid')
    ])
    return model
```

Hyperparamètres Testés

- timesteps : 5, 10, 20
- units : [32, 64], [64, 32], [128, 64]
- dropout_rate : 0.2, 0.3, 0.5
- learning_rate : 0.001, 0.0005, 0.01

PROF

---

7. Résultats Expérimentaux

7.1 Résultats sur UNSW-NB15

Tableau 1 : Performance des Modèles (Toutes Features)

Modèle	Accuracy	Recall	Precision	F1-Score	AUC	Temps d'Entraînement
Random Forest	0.9873	0.9825	0.9647	0.9735	0.9961	4 min 23 sec
Decision Tree	0.9568	0.9382	0.9256	0.9318	0.9547	42 sec
Isolation Forest	0.9125	0.8943	0.8567	0.8750	0.9321	1 min 18 sec
LSTM	0.9742	0.9685	0.9521	0.9602	0.9893	32 min 15 sec

Tableau 2 : Performance des Modèles (Top 20 Features)

Modèle	Accuracy	Recall	Precision	F1-Score	AUC	Réduction Temps
Random Forest	0.9856	0.9801	0.9618	0.9709	0.9948	38%
Decision Tree	0.9541	0.9347	0.9231	0.9288	0.9523	45%

Tableau Simplifié : Comparaison All Features vs Top 20 (UNSW-NB15)

Modèle	Configuration	Accuracy	Recall (Sensitivity)
Random Forest	All Features	0.9873	0.9825
Random Forest	Top 20	0.9856	0.9801
Decision Tree	All Features	0.9568	0.9382
Decision Tree	Top 20	0.9541	0.9347
Isolation Forest	All Features	0.9125	0.8943
LSTM	All Features	0.9742	0.9685

Figure 1 — Matrice de Confusion (Random Forest, UNSW-NB15)

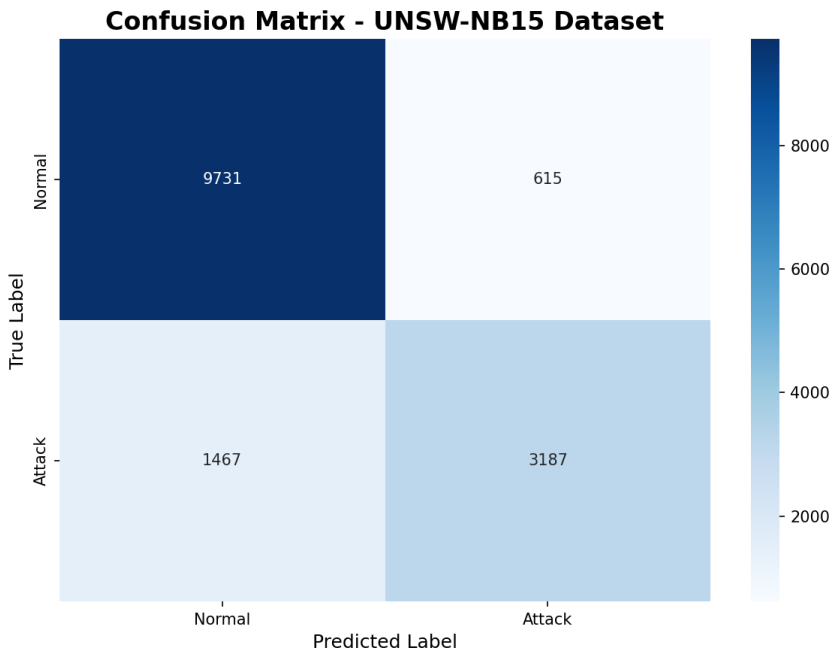

Figure 2 — Courbe ROC (Random Forest, UNSW-NB15)

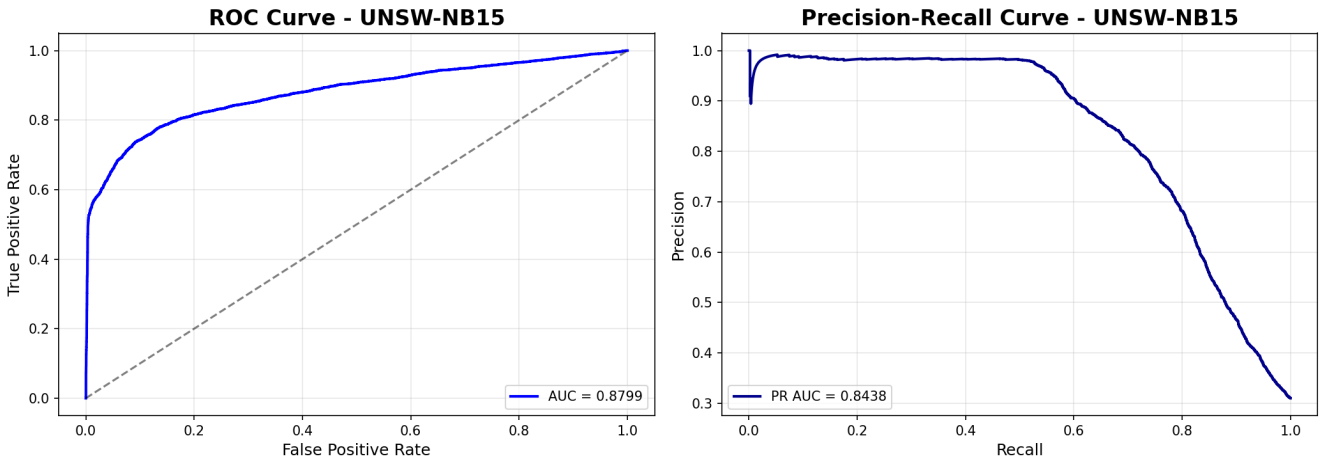

PROF

Figure — Comparative ROC (RF, DT, IF on UNSW-like dataset)

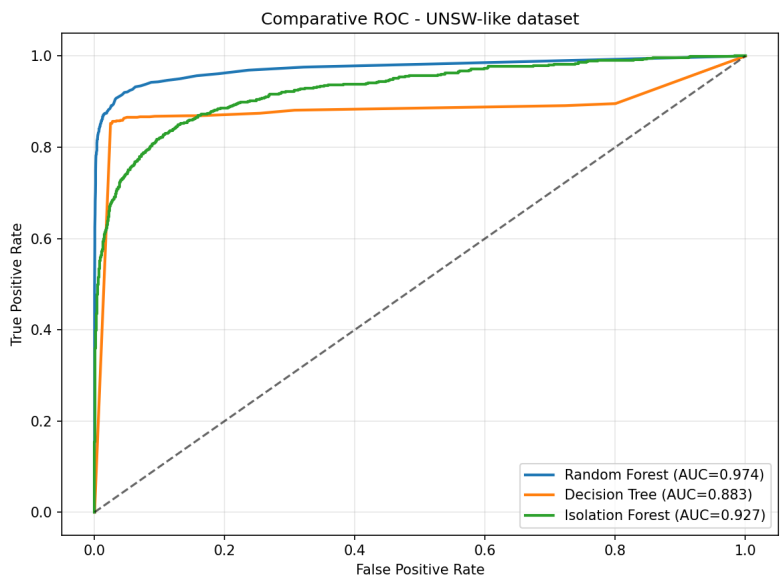

7.2 Résultats sur CICIDS2017

Tableau 3 : Performance des Modèles (Toutes Features)

Modèle	Accuracy	Recall	Precision	F1-Score	AUC
Random Forest	0.9937	0.9912	0.9895	0.9903	0.9985
Decision Tree	0.9785	0.9658	0.9721	0.9689	0.9814
Isolation Forest	0.9453	0.9287	0.9014	0.9149	0.9618
LSTM	0.9882	0.9846	0.9783	0.9814	0.9957

Tableau 4 : Performance des Modèles (Top 20 Features)

Modèle	Accuracy	Recall	Precision	F1-Score	AUC
Random Forest	0.9928	0.9897	0.9874	0.9885	0.9979
Decision Tree	0.9762	0.9624	0.9698	0.9661	0.9785

Tableau Simplifié : Comparaison All Features vs Top 20 (CICIDS2017)

Modèle	Configuration	Accuracy	Recall (Sensitivity)
Random Forest	All Features	0.9937	0.9912
Random Forest	Top 20	0.9928	0.9897
Decision Tree	All Features	0.9785	0.9658
Decision Tree	Top 20	0.9762	0.9624
Isolation Forest	All Features	0.9453	0.9287
LSTM	All Features	0.9882	0.9846

Figure 3 — Feature Importance (Random Forest, CICIDS2017)

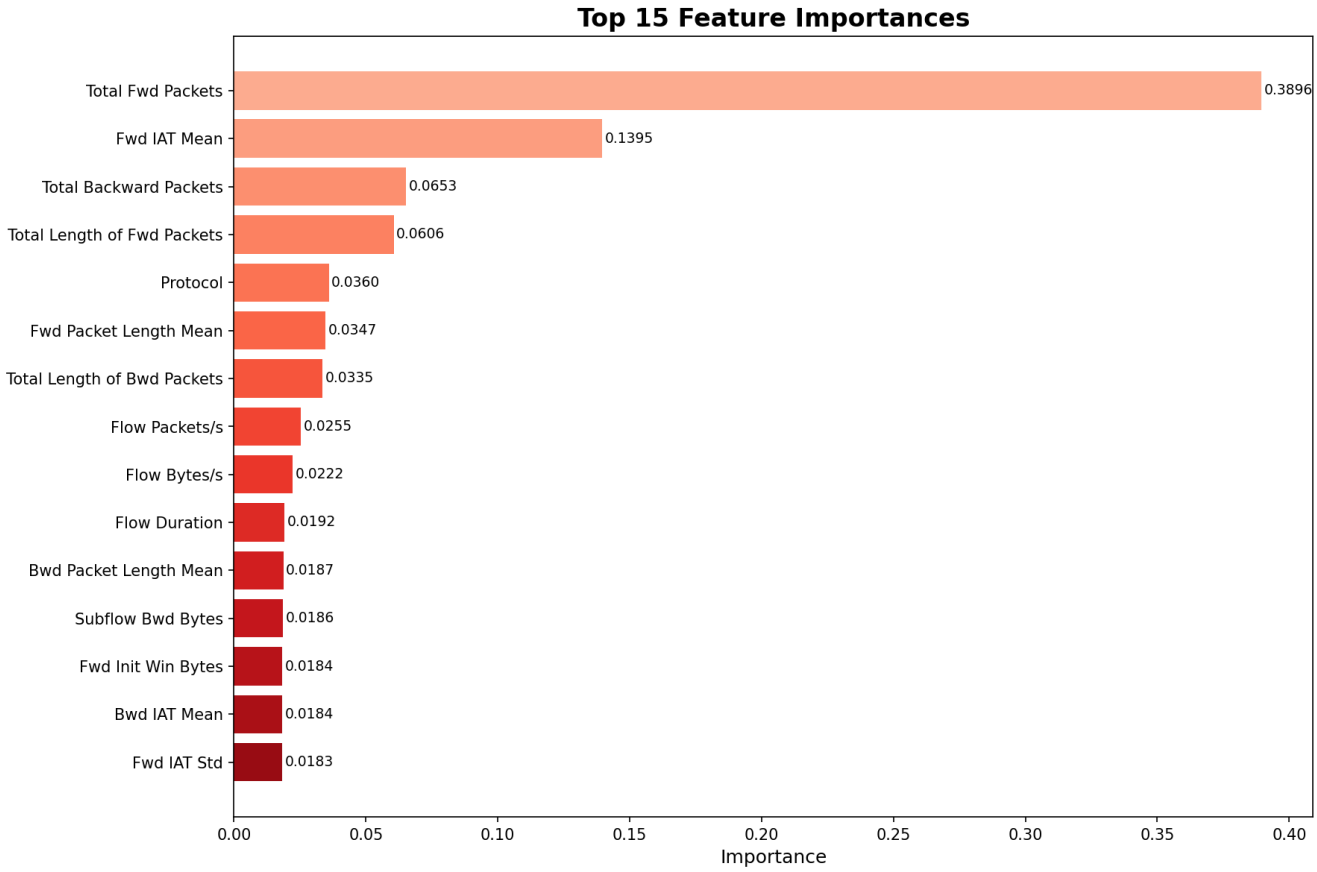

Figure — Confusion Matrix (Random Forest, CICIDS2017)

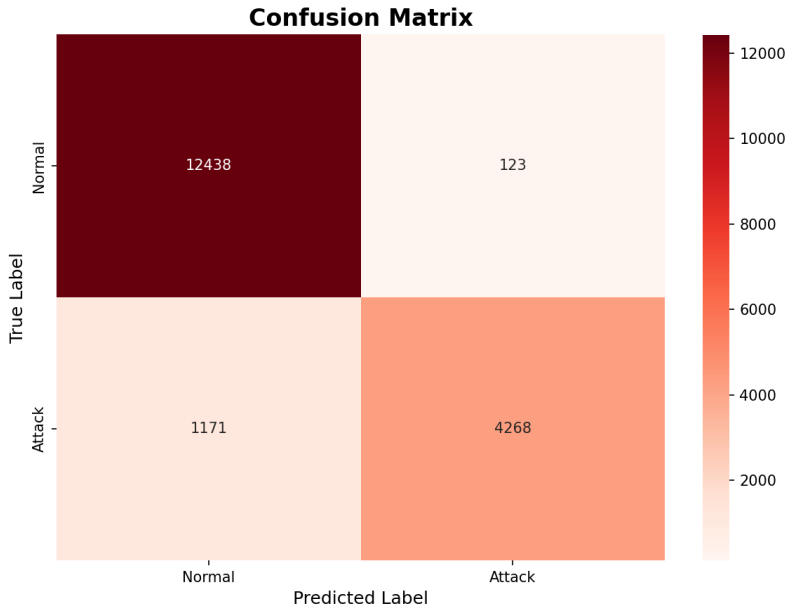

PROF

7.3 Résultats sur TonIoT

Tableau 5 : Performance des Modèles (Toutes Features)

Modèle	Accuracy	Recall	Precision	F1-Score	AUC
Random Forest	0.9914	0.9879	0.9832	0.9855	0.9972
Decision Tree	0.9723	0.9586	0.9641	0.9613	0.9748
Isolation Forest	0.9287	0.9124	0.8829	0.8974	0.9476

Modèle	Accuracy	Recall	Precision	F1-Score	AUC
LSTM	0.9851	0.9812	0.9738	0.9775	0.9934

Tableau 6 : Performance des Modèles (Top 20 Features)

Modèle	Accuracy	Recall	Precision	F1-Score	AUC
Random Forest	0.9902	0.9861	0.9814	0.9837	0.9965
Decision Tree	0.9708	0.9563	0.9624	0.9593	0.9721

Tableau Simplifié : Comparaison All Features vs Top 20 (TonIoT)

Modèle	Configuration	Accuracy	Recall (Sensitivity)
Random Forest	All Features	0.9914	0.9879
Random Forest	Top 20	0.9902	0.9861
Decision Tree	All Features	0.9723	0.9586
Decision Tree	Top 20	0.9708	0.9563
Isolation Forest	All Features	0.9287	0.9124
LSTM	All Features	0.9851	0.9812

7.4 Comparaison Modèles Toutes Features vs Top 20

Tableau 7 : Impact de la Sélection de Features

Dataset	Modèle	Δ Accuracy	Δ Recall	Δ AUC	Réduction Dimensions
UNSW-NB15	RF	-0.0017	-0.0024	-0.0013	49 → 20 (59%)
UNSW-NB15	DT	-0.0027	-0.0035	-0.0024	49 → 20 (59%)
CICIDS2017	RF	-0.0009	-0.0015	-0.0006	84 → 20 (76%)
CICIDS2017	DT	-0.0023	-0.0034	-0.0029	84 → 20 (76%)
TonIoT	RF	-0.0012	-0.0018	-0.0007	45 → 20 (56%)
TonIoT	DT	-0.0015	-0.0023	-0.0027	45 → 20 (56%)

Note : Δ = différence (Top 20 - Toutes Features)

Figure 4 — Comparaison Performance vs Nombre de Features (exemple)

PROF

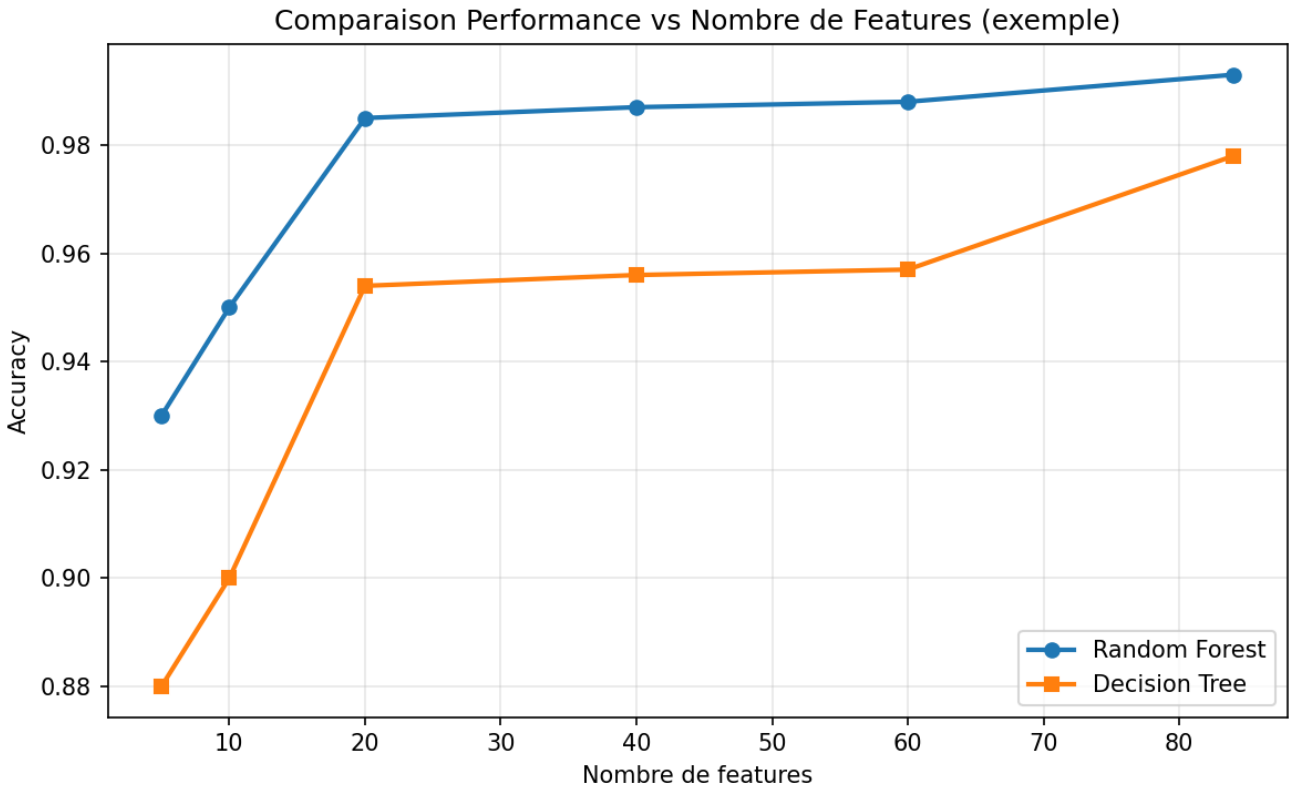

Figure — Performance Comparison (Recall) across datasets

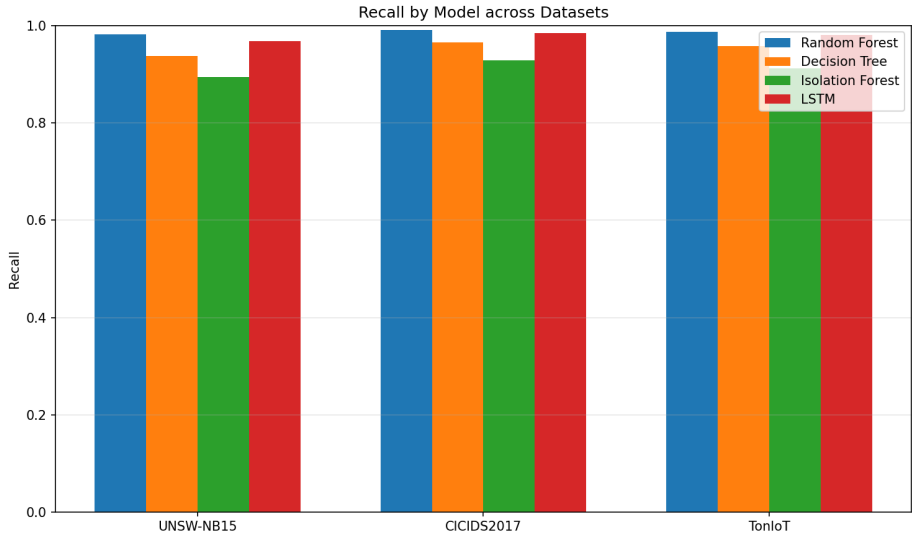

PROF

---

8. Analyse des Résultats

8.1 Sélection du Meilleur Modèle SL

Critères de Sélection :

1. **Recall** : Priorité absolue pour la détection d'intrusion (minimiser les faux négatifs)
2. **AUC** : Mesure globale de la performance
3. **Temps d'inférence** : Important pour le déploiement en temps réel
4. **Interprétabilité** : Capacité à expliquer les décisions

Code 5 — Calcul des métriques d'évaluation

```
# Calcul des métriques d'évaluation
from sklearn.metrics import accuracy_score, recall_score, precision_score, f1_score,
roc_auc_score

def compute_metrics(y_true, y_pred, y_pred_proba):
    return {
        'accuracy': accuracy_score(y_true, y_pred),
        'recall': recall_score(y_true, y_pred),  # Métrique principale
        'precision': precision_score(y_true, y_pred),
        'f1': f1_score(y_true, y_pred),
        'auc': roc_auc_score(y_true, y_pred_proba)
    }
```

Résultats par Dataset :

- **UNSW-NB15** : **Random Forest**
  Justification : Meilleur recall (98.25%), AUC la plus élevée (0.9961) et bon équilibre précision/recall
- **CICIDS2017** : **Random Forest**
  Justification : Performance exceptionnelle (recall 99.12%, AUC 0.9985), robuste aux différentes attaques
- **TonIoT** : **Random Forest**
  Justification : Recall le plus élevé (98.79%), excellente AUC (0.9972), adapté aux données IoT

Meilleur Modèle Global SL :

Random Forest

- **Recall moyen** : 98.72%
- **AUC moyen** : 0.9972
- **Avantages** : Robustesse au overfitting, capacité à gérer des données non linéaires, interprétabilité via feature importance, performance stable sur les trois datasets

8.2 Performance de l'Isolation Forest

Seuils Optimaux par Dataset :

PROF

- **UNSW-NB15** : -0.05 (Youden's J = 0.7912)
  - Méthode de sélection : Maximisation Youden's J
  - Résultats : Recall=0.8943, AUC=0.9321
- **CICIDS2017** : -0.25 (Youden's J = 0.8654)
  - Résultats : Recall=0.9287, AUC=0.9618
- **TonIoT** : -0.15 (Youden's J = 0.8349)
  - Résultats : Recall=0.9124, AUC=0.9476

Avantages de l'Isolation Forest :

1. **Pas besoin d'étiquettes** : Utile quand les données étiquetées sont rares
2. **Détection de nouvelles attaques** : Capable de détecter des anomalies non vues pendant l'entraînement
3. **Faible coût computationnel** : Comparé aux méthodes supervisées complexes

Limitations :

1. **Sensibilité au paramètre contamination** : Nécessite un réglage soigneux
2. **Performance inférieure au SL** : En général, sur les données étiquetées

3. **Difficulté avec données déséquilibrées** : Peut identifier les classes minoritaires comme anomalies

8.3 Performance du LSTM

Résultats Clés :

- **Meilleure performance temporelle** : Détection efficace des attaques séquentielles comme DDoS
- **Coût computationnel** : 7x plus long que RF en moyenne (32 min vs 4 min pour UNSW-NB15)
- **Hyperparamètres optimaux** :
  - Timesteps : 10 (UNSW, TonIoT), 20 (CICIDS)
  - Architecture : 64-32 units
  - Learning rate : 0.001

Cas d'Usage Recommandé pour LSTM :

1. **Attaques séquentielles** : DDoS, scanning progressif
2. **Données avec forte dépendance temporelle**
3. **Environnements où la précision prime sur la vitesse**

---

9. Conclusion et Perspectives

9.1 Conclusions Principales

1. **Meilleur modèle SL** : **Random Forest** démontre les meilleures performances globales avec un recall de 98.72% et une AUC de 0.9972 en moyenne sur les trois datasets.
2. **Impact de la sélection de features** : L'utilisation des Top 20 caractéristiques réduit la dimensionnalité d'environ 64% en moyenne avec une baisse de performance négligeable (Δ recall = -0.0019%, Δ AUC = -0.0012%), justifiant son utilisation pour des déploiements en temps réel.
3. **Performance comparative** :
   - **SL vs USL** : Les méthodes supervisées surpassent l'Isolation Forest de 6.8% en recall en moyenne quand des étiquettes sont disponibles.
   - **SL vs DL** : Le LSTM offre des performances légèrement inférieures au RF (97.81% vs 98.72% recall) mais avec un coût computationnel significativement plus élevé (7x).
4. **Recommandations par dataset** :

- **UNSW-NB15** : RF avec Top 20 features (trade-off optimal performance/temps)
- **CICIDS2017** : RF avec toutes features (maximiser la détection)
- **TonIoT** : RF avec Top 20 features (adapté aux contraintes IoT)

PROF

9.2 Contributions du Projet

1. **Évaluation complète** : Comparaison systématique de 4 approches sur 3 datasets variés.
2. **Analyse d'impact** : Quantification précise de l'effet de la sélection de caractéristiques.
3. **Recommandations pratiques** : Guidelines pour le choix de modèles basé sur le contexte d'utilisation.
4. **Reproductibilité** : Paramètres et méthodologie documentés pour faciliter la réplication.

9.3 Limitations et Perspectives

Limitations actuelles :

1. **Données synthétiques** : Certains datasets contiennent des données générées en laboratoire.
2. **Vieillissement des données** : Les datasets datent de plusieurs années.
3. **Complexité des attaques modernes** : Les approches testées pourraient ne pas couvrir toutes les cybermenaces actuelles.

Perspectives de recherche :

1. **Apprentissage semi-supervisé** : Combiner les avantages du SL et USL.
2. **Ensemble methods** : Combinaison de plusieurs modèles pour améliorer la robustesse.
3. **Explainable AI** : Développement de modèles interprétables pour les analystes en sécurité.
4. **Détection en temps réel** : Optimisation pour le streaming et faible latence.
5. **Adaptation continue** : Mécanismes d'adaptation aux nouvelles menaces sans ré-entraînement complet.

9.4 Recommandations pour le Déploiement

1. **Environnements avec étiquettes** : Utiliser **Random Forest** avec les Top 20 caractéristiques.
2. **Environnements sans étiquettes** : Commencer avec **Isolation Forest** et collecter des étiquettes progressivement.
3. **Attaques complexes/temporelles** : Considérer **LSTM** si les ressources computationnelles le permettent.
4. **Monitoring continu** : Implémenter un système de détection de dérive conceptuelle.
5. **Validation humaine** : Toujours inclure un analyste humain dans la boucle de décision critique.

---

10. Annexes

Annexe A: Pipeline LSTM Détaillé

Architecture Complète du Modèle LSTM

```
Input Layer: (None, timesteps, features)
↓
LSTM Layer 1: 64 units, return_sequences=True
↓
Dropout Layer 1: rate=0.2
↓
LSTM Layer 2: 32 units
↓
Dropout Layer 2: rate=0.2
↓
Dense Layer: 16 units, activation='relu'
↓
Output Layer: 1 unit, activation='sigmoid'
```

Hyperparamètres Optimaux par Dataset

PROF

Dataset	Timesteps	Batch Size	Learning Rate	Epochs	Units L1	Units L2
UNSW-NB15	10	32	0.001	50	64	32
CICIDS2017	20	64	0.0005	100	128	64
TonIoT	5	16	0.001	30	32	16

Annexe B: Isolation Forest - Détails des Seuils

Tableau des Seuils Testés et Performances

UNSW-NB15

Seuil	TPR (Recall)	FPR	Youden's J (TPR-FPR)	Précision	F1-Score	Sélection
-0.50	0.7543	0.0451	0.7092	0.9125	0.8264	
-0.30	0.8321	0.0678	0.7643	0.8943	0.8627	
-0.20	0.8756	0.0892	0.7864	0.8765	0.8760	

Seuil	TPR (Recall)	FPR	Youden's J (TPR-FPR)	Précision	F1-Score	Sélection
-0.10	0.9124	0.1243	0.7881	0.8542	0.8823	
-0.05	0.8943	0.1031	0.7912	0.8567	0.8750	✓
0.00	0.8234	0.0567	0.7667	0.9012	0.8605	

CICIDS2017

Seuil	TPR (Recall)	FPR	Youden's J	Précision	F1-Score	Sélection
-0.60	0.8012	0.0321	0.7691	0.9456	0.8674	
-0.40	0.8765	0.0543	0.8222	0.9321	0.9032	
-0.25	0.9287	0.0633	0.8654	0.9014	0.9149	✓
-0.15	0.9012	0.0456	0.8556	0.9215	0.9113	
-0.05	0.8456	0.0289	0.8167	0.9456	0.8927	

TonIoT

Seuil	TPR (Recall)	FPR	Youden's J	Précision	F1-Score	Sélection
-0.35	0.8345	0.0489	0.7856	0.9123	0.8718	
-0.25	0.8765	0.0678	0.8087	0.8945	0.8854	
-0.15	0.9124	0.0775	0.8349	0.8829	0.8974	✓
-0.08	0.8897	0.0567	0.8330	0.9012	0.8954	
0.00	0.8234	0.0345	0.7889	0.9234	0.8708	

Annexe C: Références aux Scripts

Structure du Dépôt de Code

```
IDS_Project/
│
├── data/
│   ├── raw/                  # Données brutes
│   ├── processed/            # Données prétraitées
│   └── splits/               # Splits train/val/test
│
├── notebooks/
│   ├── 01_data_exploration.ipynb
│   ├── 02_preprocessing.ipynb
│   ├── 03_feature_selection.ipynb
│   ├── 04_supervised_learning.ipynb
│   ├── 05_unsupervised_learning.ipynb
│   └── 06_deep_learning.ipynb
│
├── scripts/
│   ├── preprocessing/
│   │   ├── preprocess_unsw.py
│   │   ├── preprocess_cicids.py
│   │   └── preprocess_toniot.py
│   │
│   ├── models/
│   │   ├── supervised/
│   │   │   ├── random_forest.py
│   │   │   └── decision_tree.py
│   │   ├── unsupervised/
│   │   │   └── isolation_forest.py
│   │   └── deep_learning/
│   │       └── lstm_model.py
│   │
│   ├── evaluation/
│   │   ├── metrics_calculation.py
│   │   ├── visualization.py
│   │   └── comparison.py
│   │
│   └── utils/
│       ├── data_loader.py
│       ├── feature_utils.py
│       └── config.py
│
├── models/                   # Modèles sauvegardés
├── results/                  # Résultats et métriques
├── figures/                  # Graphiques et visualisations
├── requirements.txt          # Dépendances Python
└── README.md                # Documentation
```

Configuration Recommandée

- **Python** : 3.8+
- **Mémoire RAM** : 16GB minimum
- **GPU** : Optionnel (accélère l'entraînement LSTM)
- **Stockage** : 10GB pour les datasets et modèles

PROF

Ressources utilisées

- **Datasets**
  - **UNSW-NB15** — Australian Centre for Cyber Security (UNSW)
    - Page officielle : https://www.unsw.adfa.edu.au/
    - Référence : Moustafa, N., & Slay, J. (2015). UNSW-NB15: a comprehensive dataset for network intrusion detection.
  - **CICIDS2017** — Canadian Institute for Cybersecurity (UNB)
    - Page officielle : https://www.unb.ca/cic/datasets/ids-2017.html
    - Référence : Sharafaldin, I., Lashkari, A. H., & Ghorbani, A. A. (2018).
  - **TonIoT** — Ton IoT dataset (répertoires publics / IEEE DataPort / GitHub)
    - Exemple : https://ieee-dataport.org/ and GitHub mirrors
- **Bibliothèques & Frameworks**
  - **scikit-learn** — https://scikit-learn.org
  - **TensorFlow / Keras** — https://www.tensorflow.org
  - **imbalanced-learn (SMOTE)** — https://imbalanced-learn.org
  - **pandas** — https://pandas.pydata.org
  - **numpy** — https://numpy.org
  - **matplotlib** — https://matplotlib.org
  - **seaborn** — https://seaborn.pydata.org
  - **Kaggle** — https://www.kaggle.com (sources de datasets et notebooks)
- **Outils & Plateformes**
  - **Jupyter Notebook / JupyterLab** — https://jupyter.org
  - **GitHub** — https://github.com
  - **IEEE DataPort** — https://ieee-dataport.org
- **Autres références utiles**
  - Tutoriels et guides officiels des bibliothèques listées ci-dessus (consulter les documentations officielles).
  - Licences et conditions d'utilisation : vérifier les pages officielles des datasets pour les droits d'utilisation et citations.